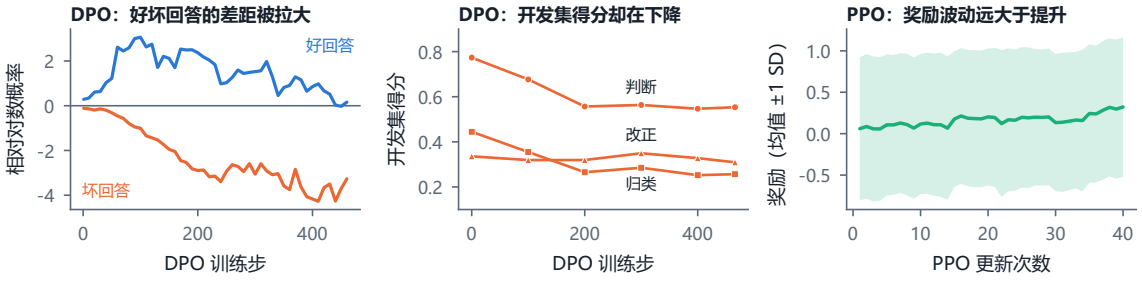
DPO：好坏回答的差距被拉大
好回答
坏回答
相对对数概率
2
0
-2
-4
0
200
400
DPO 训练步
DPO：开发集得分却在下降
判断
改正
归类
开发集得分
0.8
0.6
0.4
0.2
0
200
400
DPO 训练步
PPO：奖励波动远大于提升
奖励（均值 ±1 SD）
1.0
0.5
0.0
-0.5
0
10
20
30
40
PPO 更新次数