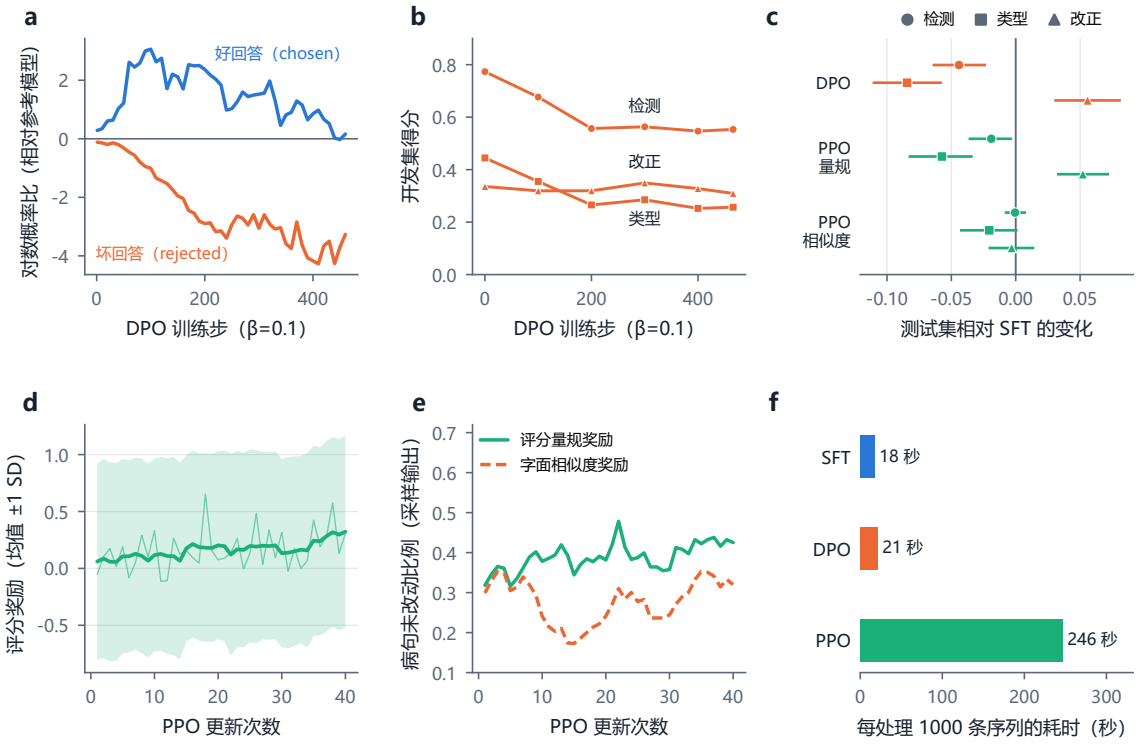

a
对数概率比（相对参考模型）
好回答（chosen）
坏回答（rejected）
2
0
-2
-4
0
200
400
DPO 训练步（β=0.1）
b
开发集得分
检测
改正
类型
0.8
0.6
0.4
0.2
0.0
0
200
400
DPO 训练步（β=0.1）
c
检测
类型
改正
DPO
PPO
量规
PPO
相似度
-0.10
-0.05
0.00
0.05
测试集相对 SFT 的变化
d
评分奖励（均值 ±1 SD）
1.0
0.5
0.0
-0.5
0
10
20
30
40
PPO 更新次数
e
病句未改动比例（采样输出）
评分量规奖励
字面相似度奖励
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
10
20
30
40
PPO 更新次数
f
SFT
18 秒
DPO
21 秒
PPO
246 秒
0
100
200
300
每处理 1000 条序列的耗时（秒）